

8-2. Rethinking Calibration

딥러닝 모델의 **캘리브레이션 성능**은 과신(overconfidence)을 줄이는 것이 아니라, 쉬운 샘플과 어려운 샘플을 얼마나 잘 구분하는지에 달려있습니다. 기존의 과신 완화 기법들은 오히려 캘리브레이션 본질을 해칠 수 있습니다.

1. 딥러닝 모델 캘리브레이션의 재고찰: 과신을 두려워하지 말라

딥러닝 모델의 캘리브레이션 성능은 단순히 과신을 줄이는 것이 아니라, 쉬운 샘플과 어려운 샘플을 얼마나 잘 구분하는지에 달려있다는 새로운 관점을 제시한다.

1.1. 캘리브레이션과 관련 연구 분야

**Rethinking Calibration of Deep Neural Networks:
Do Not Be Afraid of Overconfidence, NIPS 2021. (20회 인용)**

Korea University
School of Industrial & Management Engineering
Data Science & Business Analytics Lab

DSBA 세미나

석박통합과정 박경찬

1. 딥러닝 모델은 높은 성능을 보이지만, 예측이 틀렸을 때에 대한 대비가 부족하다.
 - a. 실제 환경에서는 다양한 외부 변수로 인해 모델이 예기치 못하게 잘못된 예측을 할 수 있다.
 - b. 모델의 예측이 불확실할 때 정보를 제공하면 이러한 문제를 방지할 수 있다.
2. 캘리브레이션과 유사한 연구 분야는 다음과 같다.
 - a. 모델 캘리브레이션

- b. 언어 설정 추정
 - c. 로버스트닝
 - d. 불확실성 추정
3. 불확실성 추정은 모델의 예측 결과에 대한 불확실성을 정량화하는 것을 목적으로 한다.
- a. 베이지안 뉴럴 네트워크가 불확실성을 정량화하는 대표적인 방법론이다.
 - b. 불확실성 추정은 이상 탐지나 이상 감지(아웃라이어 디텍션)에 응용될 수 있다.

1.2. 모델 캘리브레이션의 정의와 필요성

1. 모델 캘리브레이션은 딥러닝 모델의 분류 결과로 나오는 **컨피던스 값**이 실제 확률값과 일치하도록 교정하는 연구 분야이다.
2. 딥러닝 모델이 복잡해지고 고도화될수록 분류 성능은 향상되었지만, 캘리브레이션 성능은 오히려 낮아졌다.
 - a. 이는 딥러닝 모델이 **오버컨피던스(overconfidence)** 아웃풋을 산출하는 경향이 강해졌기 때문이다.
 - b. 오버컨피던스는 모델의 예측이 틀렸을 때에도 매우 높은 컨피던스 값을 도출하는 현상을 의미한다.
3. 딥러닝 모델의 컨피던스 값 분포는 높은 쪽에 데이터가 많이 분포되어 오버컨피던스 경향이 강하게 나타난다.
 - a. 반면, 구식 모델은 컨피던스 값이 고르게 분포한다.
4. 캘리브레이션 성능을 시각적으로 평가하는 자료로 **릴라이어빌리티 다이어그램**이 있다.
 - a. 빨간색 갭이 작을수록 캘리브레이션 성능이 좋다.
 - b. 딥러닝 모델은 릴라이어빌리티 다이어그램 상에서 성능이 좋지 않게 나타난다.

1.3. 캘리브레이션 성능 측정 지표 및 기존 기법




1 Background

1. 캘리브레이션 성능을 측정하는 주요 지표는 **릴라이어빌리티 다이어그램**과 **ECE(Expected Calibration Error)**이다.
 - a. **릴라이어빌리티 다이어그램**: 컨피던스 값을 M개로 균등 분할한 후, 각 bin에 속하는 데이터들의 평균 정확도와 컨피던스 값을 계산하여 시각화한다.
 - i. 정확도는 파란색 막대그래프로, 정확도와 컨피던스의 차이는 빨간색으로 표시하여 캘리브레이션 정도를 보여준다.
 - ii. 만약 실제 정확도가 컨피던스보다 낮으면 빨간색 갭이 커져 캘리브레이션 성능이 좋지 않음을 직관적으로 알 수 있다.
 - b. **ECE**: 캘리브레이션 성능을 측정하는 정량적 지표이다.
2. 딥러닝 모델은 복잡해질수록 **ECE**가 증가하는 경향을 보인다.
 - a. 모델의 깊이와 필터 개수를 늘리면 분류 성능(에러)은 줄어들지만, ECE는 증가한다.
 - b. 배치 노말라이제이션을 적용할 때도 ECE는 증가한다.
3. 가중치를 크게 적용할수록 ECE는 줄어드는 경향이 강하다.
4. 딥러닝 모델의 표현 역량과 성능을 높이면 분류 성능은 개선되지만, 캘리브레이션 성능은 떨어지는 경향이 있다.
5. 캘리브레이션 성능을 높이기 위한 방법론은 크게 두 가지로 나뉜다.
 - a. **포스트 오브 캘리브레이션(Post-hoc Calibration)**: 학습된 모델의 아웃풋에 대한 후처리 과정을 통해 성능을 향상시킨다.

- i. 대표적인 방법으로는 **템퍼러처 스케일링(Temperature Scaling)**과 **히스토그램 바이닝(Histogram Binning)**이 있다.
- b. **모델 레귤러라이제이션(Model Regularization)**: 학습 과정에서 레귤러라이제이션을 가하여 모델의 출력이 과신되지 않도록 학습한다.
 - i. 대표적인 방법으로는 **라벨 스무딩(Label Smoothing)**과 **EPINOMIN 더 평선 스페이스(EPINOMIN Function Space)**가 있다.

1.4. 포스트 오브 캘리브레이션 방법론



13

1. **템퍼러처 스케일링**: 소프트맥스 레이어 이전에 산출되는 아웃풋에 적절한 값(t , 템퍼러처)을 나누어주는 후처리 방법이다.
 - a. 템퍼러처(t)를 1보다 크게 하면 오버컨피던스 현상이 완화되어 캘리브레이션 성능이 증가할 수 있다.
 - b. t 가 무한대로 가면 컨피던스 분포는 유니폼 분포가 되고, t 가 0으로 수렴하면 매우 벡터 형태가 된다.
2. **히스토그램 바이닝**: 검증 셋의 컨피던스 스코어에 따라 0부터 1까지의 범위를 n 개로 분할한 후, 각 구간에 해당하는 샘플들의 캘리브레이드된 컨피던스를 해당 구간의 실제 정밀도(accuracy)로 대체한다.
 - a. 범위를 분할하는 기준은 컨피던스 스코어에 따른 균등 분할 또는 검증 셋 데이터의 마스에 따른 균등 분할 등이 있다.

- b. 히스토그램 바이닝은 모든 샘플이 총 n개의 컨피던스를 갖도록 조정되므로, 스파르탄한(희박한) 컨피던스 스코어가 산출되는 단점이 있다.

1.5. 모델 레귤러라이제이션 방법론



Background

Model Regularization: Focal Loss

- ✓ Focal Loss는 class간의 불균형이 존재하는 상황에서 학습이 다수 class에 overfitting되지 않도록 하기 위해 설계된 loss로 이를 적용했을 때, calibration performance가 증가한다는 것이 밝혀짐

$$L_{CE} = -\log f_y^\theta \Rightarrow L_f = -(1 - f_y^\theta)^\gamma \log f_y^\theta$$

- ✓ 즉 confidence 값인 f_y^θ 가 높은 sample들은 학습 과정에서 배제되도록 유도함
- ✓ Focal Loss는 regularized KL-divergence의 upper bound임이 증명되었으며, 결국 모델의 confidence output의 entropy가 증가하도록 regularization을 가한다고 볼 수 있음

$$L_f \geq KL(y|f^\theta) - \gamma H(f^\theta)$$

15

- 밸리데이션 로스(Validation Loss):** 클래스 간 불균형 상황에서 다수 클래스에 대한 오버피팅을 방지하기 위해 설계된 손실 함수이다.
 - 네거티브 로짓 값을 적용했을 때 캘리브레이션 성능이 향상된다.
 - 이 손실 함수는 컨피던스 값이 높은 샘플들을 학습 과정에서 배제하도록 유도한다.
- 보컬로스(Vocal Loss):** 정규화된 KL 다이버전스의 상한선으로 증명되었으며, 모델의 확률 출력 엔트로피가 증가하도록 정규화를 가하는 손실 함수이다.
- 라벨 스무딩(Label Smoothing):** 딥러닝 모델의 과적합을 방지하기 위해 원래의 라벨 벡터를 소프트 라벨 벡터로 대체하는 기법이다.
 - 입실론(epsilon)은 하이퍼파라미터로 라벨에 대한 불확실성 정도를 의미한다.
 - 라벨 스무딩을 적용하면 손실 함수는 하이퍼파라미터 입실론의 크기에 따라 확률 출력의 엔트로피를 증가시키도록 유도한다.
- EPINOMIN 더 평션 스페이스(EPINOMIN Function Space):** 캘리브레이션 성능을 높이기 위해 개발된 보완 기법으로, 소프트맥스 레이어 이전에 도출되는 로직 벡터(g세타)에 직접적인 규제 함수를 변경한다.
 - 알파(alpha)는 하이퍼파라미터로 정규화 강도를 조절한다.

- b. 로직 벡터(g세타)에 대한 규제 강도를 조절하는 방법이다.
- c. 소프트맥스 계산 시 지수 함수를 활용하기 때문에 값이 클수록 지수적으로 증가하여 오버컨피던스가 심해질 수 있는데, 로직 벡터를 직접 규제함으로써 오버컨피던스 경향을 완화한다.

1.6. 기존 모델 기반 캘리브레이션 방법론의 한계




Background

Model based Calibration Method 한계점

- ✓ 기존의 model based calibration method들은 결국 딥러닝 모델이 overconfidence output을 도출한다는 결과에만 집중함
- ✓ 따라서 overconfidence output을 도출하지 못하도록 regularization loss를 추가하는 방식으로 방법론이 제한되었고 그렇기 때문에 당연히 calibration performance가 수치적으로 증가할 수 밖에 없음
- ✓ 하지만 아래 그림에서 볼 수 있듯이 분류 성능이 약 20% 가까이 높은 고도화된 모델인 ResNet이 calibration 관점에서는 성능이 낮다는 것은 의아한 결과라고 볼 수 있음

→ 그렇다면 calibration 성능이 좋다는 것의 본질은 무엇일까에 대한 고찰이 필요함



18

1. 기존 모델 기반 캘리브레이션 방법들은 딥러닝 모델이 오버컨피던스 아웃풋을 도출한다는 결과에만 집중했다.
 - a. 따라서 오버컨피던스 아웃풋이 나오지 않도록 레귤러라이제이션 손실을 추가하는 방식으로 방법론이 제한되었다.
2. 이러한 방식으로 캘리브레이션 퍼포먼스는 수치적으로 향상되었지만, 분류 성능이 높은 고도화된 모델(ResNet)은 캘리브레이션 관점에서 성능이 낮다는 의아한 결과가 나타났다.
3. 수치적 결과가 좋다고 해서 반드시 좋은 성능을 의미하는 것은 아니며, 캘리브레이션 성능의 본질에 대한 고찰이 필요하다.
4. 모델의 캘리브레이션 성능에 대한 본질을 확인하기 위해 몇 가지 실험을 진행하였다.

1.7. 모델 기반 캘리브레이션 기법들의 캘리브레이션 성능 분석

- ✓ 본 논문에서는 우선 model based calibration 기법들의 calibration performance에 대한 분석을 진행함
- ✓ 실제로 각 기법들을 적용했을 때, Cross-Entropy Loss에 비하여 calibration performance가 증가하는 것을 확인함
- ✓ SVHN과 CIFAR10, 100에 대해서는 ResNet-32 모델을 사용하였고, 20 Newsgroups 데이터셋에 대해서는 8-layer 1D CNN을 사용함
- ✓ 모든 결과에서 cross-entropy 대비 calibration performance가 증가하였고, accuracy는 다소 감소하는 경향을 보임

Table 1: Comparison results (mean $\pm$ std) of ECE (%) with $M = 15$ and predictive accuracy (%) over 5 random runs. The values with underline in first row represent the chosen coefficients of each regularization method on four datasets according to the ECE on test data.

		Cross-Entropy	Label Smoothing <u>0.01/0.05/0.09/0.09</u>	L_1 Norm <u>0.01/0.05/0.01/0.01</u>	Focal Loss <u>1/3/5/5</u>
SVHN	ECE	3.03 $\pm$ 0.16	1.84 $\pm$ 0.19	1.85 $\pm$ 0.04	1.01 $\pm$ 0.21
	Accuracy	95.00 $\pm$ 0.27	95.21 $\pm$ 0.23	95.29 $\pm$ 0.13	94.77 $\pm$ 0.19
CIFAR-10	ECE	6.43 $\pm$ 0.22	2.72 $\pm$ 0.32	2.93 $\pm$ 0.39	3.00 $\pm$ 0.26
	Accuracy	90.46 $\pm$ 0.23	90.09 $\pm$ 0.41	90.06 $\pm$ 0.59	87.84 $\pm$ 0.17
CIFAR-100	ECE	19.53 $\pm$ 0.36	2.27 $\pm$ 0.48	8.07 $\pm$ 0.44	2.34 $\pm$ 0.35
	Accuracy	64.64 $\pm$ 0.43	63.73 $\pm$ 0.67	63.07 $\pm$ 0.29	60.36 $\pm$ 0.44
20 Newsgroups	ECE	20.82 $\pm$ 0.93	5.85 $\pm$ 0.64	13.31 $\pm$ 0.56	3.82 $\pm$ 0.51
	Accuracy	72.85 $\pm$ 0.89	72.81 $\pm$ 0.26	73.61 $\pm$ 0.80	59.17 $\pm$ 1.81

20

1. 각 기법들을 적용했을 때 단순 크로스 엔트로피 손실에 비해 캘리브레이션 퍼포먼스가 향상되는 것을 확인하였다.
 - a. 실험에는 SVHN 14,100 데이터와 20 뉴스 그룹 데이터셋을 사용하였다.
2. 모델 기반 캘리브레이션 기법들은 레귤러라이제이션 메서드를 적용했을 때 ECE로 측정되는 캘리브레이션 퍼포먼스가 더 좋았다.
3. 각 방법론들은 모델에 레귤러라이제이션을 가해주기 때문에, 정확도(accuracy)가 다소 감소하는 경향을 보인다.
4. 각 방법론의 하이퍼파라미터에 따른 ECE 비교 결과, 하이퍼파라미터 값에 따라 캘리브레이션 성능이 민감하게 변하는 것을 확인하였다.
5. 학습 데이터 개수를 조절하며 각 조건에서의 베스트 하이퍼파라미터 값을 그래프로 나타낸 결과, 학습 데이터 개수가 증가할수록 베스트 하이퍼파라미터는 감소하는 경향을 보였다.
 - a. 이는 데이터가 충분할수록 정규화를 약하게 하는 것이 좋다는 결론으로 이어진다.

1.8. 포스트 캘리브레이션 적용 시 결과 분석

1. 모델 기반 캘리브레이션 기법들과 크로스 엔트로피 손실 함수에 대해 포스트 캘리브레이션을 적용하여 결과를 비교하였다.
2. 아이러니하게도 모델 기반 방법론들의 성능은 오히려 하락하였으며, 크로스 엔트로피 손실에서는 성능이 크게 향상되었다.

- a. 파란색 세모는 성능 하락(훈련 시기 증가), 빨간색 세모는 ECE 하락(성능 개선)을 의미한다.
 - b. 대부분의 경우에서 모델의 ECE 성능이 개선되었으며, 특히 크로스 엔트로피 손실에서 ECE가 크게 하락하여 캘리브레이션 성능이 훨씬 좋았다.
3. 모델의 정규화(레귤러라이제이션)를 적용하여 오버컴피던스를 방지하는 기법들은 단순히 confidence 값을 통해 ECE를 측정할 때는 잘 되지만, 포스트 캘리브레이션을 적용하면 오히려 캘리브레이션 성능에 좋지 않은 영향을 끼친다.
 4. 릴라이어빌리티 다이어그램을 통해 확인했을 때도 크로스 엔트로피 손실에서 성능이 훨씬 우수하다.

1.9. 캘리브레이션 성능의 본질에 대한 고찰

2

Paper

From Calibrated to Calibratable: A Closer Look

- ✓ 앞 선 실험 결과들을 통해 model에 regularization을 주어 over confidence를 방지하는 기법들은 오히려 post-hoc calibration을 적용했을 때 성능이 하락하는 것을 확인함
- ✓ 따라서 본 논문에서는 이런 실험 결과가 나온 원인을 파악하기 위하여 calibration performance의 본질에 대해 고찰함
- ✓ 우선 이에 대한 첫 번째 실험으로 Temperature Scaling을 적용했을 때, 각 epoch마다 ECE의 변화를 관찰함
- ✓ 그 결과 Label Smoothing 기법의 경우 각 데이터셋에서 특정 epoch 이후에 ECE가 크게 증가하는 것을 확인할 수 있음
- ✓ 또한 regularization을 강하게 주었을 때 ECE가 더욱 증가하는 것을 확인할 수 있음




Figure 4: Curves of optimal ECE (%) during learning epochs using label smoothing with different coefficients. Dark colors show the mean results of 5 random runs and light colors show the ranges between minimal and maximum results of 5 runs.

24

1. 모델의 정규화(레귤러라이제이션)를 적용하여 오버컴피던스를 방지하는 기법들은 포스트 캘리브레이션을 적용했을 때 오히려 성능이 하락하였다.
2. 이러한 실험 결과의 원인을 파악하기 위해 캘리브레이션 성능의 본질에 대해 고찰하였다.
3. **Temperature scaling**을 적용했을 때, **라벨 스무딩** 기법의 경우 특정 온도 이후에 ECE가 크게 증가하는 것을 확인하였다.
 - a. 레귤러라이제이션 강도를 높게 할수록 ECE가 더욱 증가했다.

4. 크로스 엔트로피 손실은 에폭이 진행됨에 따라 ECE가 계속 하락하는 경향을 보이는 반면, 라벨 스무딩 기법은 특정 에폭 이후 줄어들다가 다시 ECE가 증가하는 경향을 보인다.
 - a. 라벨 스무딩의 정규화 강도 하이퍼파라미터 값이 클수록 그 경향이 더 심하다.
5. 딥러닝 모델은 학습 초기에는 쉬운 샘플(easy sample)을 학습하고, 학습이 진행됨에 따라 점차 어려운 샘플(hard sample)에 집중하는 **메모리제이션 효과**가 있다.
6. 모델 기반 캘리브레이션 방법이 포스트 캘리브레이션을 적용했을 때 성능이 떨어지는 이유는, 레귤러라이제이션으로 인해 학습 초기의 쉬운 샘플에 대한 신뢰도가 낮아지도록 유도하기 때문이다.
 - a. 결국 쉬운 샘플과 어려운 샘플 간의 신뢰도 차이 정보를 손실하게 된다.
7. 캘리브레이션 성능의 본질은 ECE라는 수치로서 대변되는 것이 아니라, 모델이 얼마나 샘플의 어려움을 잘 대변하는 **신뢰도(Confidence)**를 나타내는가에 대한 것이다.
8. 모델 기반 캘리브레이션 방법론을 적용하면, 쉬운 샘플과 어려운 샘플을 구별할 수 있는 능력이 상실된다.
9. 레귤러라이제이션은 오버컴피던스 아웃풋을 산출하지 못하게 하여 수치적으로는 ECE를 향상시켰지만, 본질적인 캘리브레이션 퍼포먼스에는 오히려 악영향을 끼쳤다.

1.10. 새로운 손실 함수: 인버스 보컬로스(Inverse Vocal Loss) 제안

1. 캘리브레이션 퍼포먼스의 본질은 쉬운 샘플과 어려운 샘플을 잘 구분하는 것에 있다는 것을 파악하였다.
2. 학습 후반부에도 이미 정분류하고 있는 쉬운 샘플에 대해 더욱 집중할 수 있도록 **인버스 보컬로스(Inverse Vocal Loss)**를 제안하였다.
 - a. 인버스 보컬로스는 보컬로스와 비교하여 부호가 반대로 되어 있다.
 - b. 컨피던스 값이 크면 학습에서 배제되도록 유도하는 보컬로스와 달리, 인버스 보컬로스는 그 반대의 작용을 한다.
3. 인버스 보컬로스는 딥러닝 모델의 아웃풋에서 오버컴피던스 경향을 더욱 증가시키지만, 쉬운 샘플과 어려운 샘플을 구별하는 정보는 손실되지 않고 오히려 내포할 수 있도록 모델을 학습시킨다.
4. 인버스 보컬로스는 쉬운 샘플과 어려운 샘플을 더욱 잘 구별하도록 설계된 손실 함수이다.

5. 실험 결과, 인버스 보컬로스는 다른 손실 함수에 비해 높은 컨피던스 값을 가지더라도 높은 로스 값이 계산된다.
 - a. 이는 학습 후반부에도 높은 샘플들이 지속적으로 학습되도록 유도한다.
6. 인버스 보컬로스는 레귤러라이제이션이 아니기 때문에, 어려운 데이터셋에서는 오히려 정확도가 소폭 향상된다.
7. 포스트 캘리브레이션을 적용하지 않은 경우에는 매우 오버컨피던스하다.
8. 포스트 캘리브레이션을 적용하면 오버컨피던스 경향이 줄어들어 ECE가 낮아지지만, 데이터셋에 따라 일관된 결과를 보여주지는 못한다.
 - a. 이는 데이터셋의 학습 데이터 개수나 난이도 등의 영향으로 판단된다.
9. 사용하는 모델에 따라서도 인버스 보컬로스의 성능이 일관되지 않은 결과를 보일 확률이 높다.
10. 인버스 보컬로스는 확정적으로 캘리브레이션 퍼포먼스를 향상시켜 주는 것은 아니며, 특정 데이터셋과 모델 조합에서 CE보다 성능이 있을 수 있는 기법이다.
 - a. 최소한 실제 내재적인 캘리브레이션 퍼포먼스를 하락시키는 규제 방법들보다는 캘리브레이션이 좋다고 말할 수 있다.

1.11. 결론 및 논문의 기여



1. **온 캘리브레이션(On Calibration)** 논문에서 고도화된 모델일수록 오버컨피던스 경향으로 인해 캘리브레이션 성능이 낮아진다는 점이 지적되었다.

2. 이후 연구들은 오버컴피던스라는 수치적 결과에 집중하여 이를 완화하기 위한 규제 기법들을 도입했다.
3. 본 논문은 오버컴피던스라는 수치적 특성이 실제로 모델의 내재적인 캘리브레이션 퍼포먼스와 관련이 있는지 의문을 제기하고, 실험을 통해 캘리브레이션의 본질적인 의미를 밝혔다.
4. 기존의 정규화 방법들이 오히려 모델의 캘리브레이션 퍼포먼스에 악영향을 준다는 것을 보여주고, 이를 기반으로 새로운 **인버스 보컬로스**를 제안하였다.
5. 새롭게 제안한 인버스 보컬로스는 일관되거나 드라마틱한 성능 향상을 보이지는 않았지만, 기존 캘리브레이션 모델의 성능에 대한 오해를 바로 잡았다는 점에서 유의미하다.
6. 딥러닝 모델의 캘리브레이션 성능이 무엇인지에 대한 본질적인 해석을 제공했다는 점이 이 논문의 주요 기여이다.