


STEP 4. GNN 이론 — 연구의 핵심 (4~6주)

그래프 신경망(GCN)의 핵심은 무엇인가? GCN은 이미지나 텍스트와 달리 복잡한 관계를 가진 그래프 형태의 데이터를 처리하기 위해 노드와 �지의 정보를 활용하며, **가중치 공유와 지역적 특징 추출**이라는 CNN의 장점을 그래프에 적용한 모델입니다.

1. 그래프 신경망(GCN)의 기본 개념 및 필요성

그래프 신경망(GCN)은 이미지나 텍스트와 달리 복잡한 관계를 가진 그래프 형태의 데이터를 처리하기 위해 등장했다.



1.1. 기존 데이터 표현 방식의 한계

1. 데이터 표현 방식의 변화

- 이미지는 픽셀이 격자 형태로 배열되며, 흑백은 채널 1개, 컬러는 RGB 채널 3개로 표현된다.
- 텍스트나 음성 같은 순차 데이터는 단어나 문자가 특정 순서로 연결된 시퀀스로 표현된다.
- 기존의 CNN이나 RNN은 이러한 이미지 및 순차 데이터 처리에 특화되어 있다.

2. 새로운 데이터 형태의 등장

- 이미지나 텍스트 외에도 다양한 형태의 데이터가 존재한다.
- **소셜 그래프**: 페이스북과 같은 플랫폼에서 사용자 간의 관계를 나타낸다.

- **3D 메시**: 게임이나 영상에서 사용되는 3차원 구조이다.
- **분자 그래프**: 화학 분야에서 분자의 구조를 나타낸다.
- 이러한 데이터들은 그래프 형태로 구현된다는 공통점이 있다.

1.2. 그래프의 정의 및 구성 요소

1. 그래프의 정의

- 컴퓨터 과학에서 그래프는 정점(vertex)들의 집합(V)과 이 정점들을 연결하는 간선(edge)들의 집합(E)으로 정의된다.
- 정점은 '점'으로, 간선은 '선'으로 이해할 수 있다.
- 정점 집합과 간선 집합이 주어지면 하나의 그래프를 그릴 수 있다.

2. 그래프의 종류 및 특징

- **방향성**: 간선에 방향이 없는 것을 '무방향 그래프(undirected graph)'라고 하며, 방향이 있는 것을 '방향 그래프(directed graph)'라고 한다.
- **가중치**: 간선에 거리나 중요도 같은 값을 부여할 수 있으며, 이를 '가중치(weight)'라고 한다. 가중치가 있는 그래프를 '가중치 그래프(weighted graph)'라고 한다.
- 가중치가 없는 그래프는 '비가중치 그래프(unweighted graph)'라고 한다.

1.3. 그래프 데이터의 컴퓨터 표현 방식

1. 소셜 그래프와 분자 그래프의 예시

- **소셜 그래프**:
 - 정점: 사용자 (사람)
 - 정점 정보: 이름, 나이 등 사용자 개인 정보
 - 간선: 사용자 간의 관계 (친구, 메시지 교환 빈도 등)
- **분자 그래프**:
 - 정점: 원자 (atom)
 - 정점 정보: 원자의 종류 (탄소, 수소 등)
 - 간선: 원자 간의 결합 (단일 결합, 이중 결합 등)


2. 정점(노드)과 간선(엣지)의 표현

- 정점은 '노드(node)'라고도 불리며, 앞으로 주로 '노드'로 지칭한다.
- 그래프 데이터를 컴퓨터에서 처리하기 위해서는 이산적인 형태로 표현해야 한다.
- GCN에서는 **인접 행렬(Adjacency Matrix)**과 **노드 특징 행렬(Node Feature Matrix)**을 사용하여 그래프를 표현한다.
- **인접 행렬 (Adjacency Matrix)**

- 정점 간의 연결 정보를 나타낸다.
- 크기는 (노드 수) x (노드 수)이며, i 행 j 열의 값은 i 번째 노드와 j 번째 노드가 연결되어 있는지 여부를 나타낸다 (연결 시 1, 미연결 시 0).
- i 행은 i 번째 노드가 다른 노드들과 어떻게 연결되어 있는지를 보여준다.
- **노드 특징 행렬 (Node Feature Matrix)**
 - 각 노드가 가진 정보를 나타낸다.
 - 크기는 (노드 수) x (특징 수)이며, 각 행은 특정 노드의 정보를 나타낸다.
 - 특징 수는 설정에 따라 달라질 수 있다 (예: 색상 정보, 원자 정보 등).
 - 예시: 이미지의 색상 정보는 RGB 값으로, 분자 그래프에서는 원자의 종류나 속성으로 표현될 수 있다.
 - 간선에 추가 정보가 필요할 경우, 인접 행렬에 더 다양한 값을 사용하거나 별도의 행렬을 사용할 수 있다.

2. 컨볼루션 신경망(CNN)의 핵심 원리

CNN은 이미지와 같은 격자 구조 데이터에서 지역적 특징을 효과적으로 추출하는 데 강점을 가진다.



2.1. 컨볼루션 연산과 지역적 특징 추출

1. 컨볼루션 연산 과정

- 이미지에 작은 필터(커널)를 이동시키며 합성곱 연산을 수행하여 새로운 특징 맵을 생성한다.
- 필터는 이미지의 특정 영역과 합성곱 연산을 통해 하나의 값을 추출한다.
- 필터를 이미지 위로 슬라이딩하는 과정을 '스트라이드(stride)'라고 한다.

- 패딩(padding)을 사용하여 입력 텐서의 크기를 조절할 수 있다.
- 이 과정을 통해 생성된 새로운 텐서를 '활성화 맵(activation map)'이라고 한다.
- 여러 개의 필터를 사용하면 활성화 맵의 깊이가 결정된다.
- 이러한 연산을 '컨볼루션(convolution)'이라고 하며, 컨볼루션 레이어의 핵심 연산이다.

2. 지역적 특징 추출의 중요성

- 컨볼루션 연산에서 필터가 닿는 영역은 해당 뉴런이 볼 수 있는 '지역(receptive field)'이 된다.
- 레이어가 깊어질수록 누적되는 지역은 점차 넓어진다.
- 이는 얇은 부분에서는 좁은 지역의 특징을, 깊은 부분에서는 넓은 지역의 특징을 학습할 수 있음을 의미한다.

2.2. CNN의 핵심 특징: 가중치 공유와 지역적 특징 학습

1. 가중치 공유 (Weight Sharing)

- MLP(Multi-Layer Perceptron)는 각 노드가 이전 레이어의 모든 노드와 연결되어 파라미터 수가 매우 많아지는 문제가 있다.
- 이미지에서 작은 변화(예: 한 픽셀 이동)에도 민감하게 반응하여 다른 결과가 나올 수 있다.
- CNN에서는 동일한 필터(작은 가중치 세트)를 이미지 전체에 적용하여 가중치를 공유한다.
- 이는 파라미터 수를 크게 줄여 모델의 복잡성을 낮추고 학습 시간을 단축시킨다.
- 텍스트 데이터에서도 단어의 의미를 추출하기 위해 동일한 가중치를 적용하는 것은 가중치 공유의 예시이다.

2. 지역적 특징 학습 (Local Feature Learning)

- CNN의 필터는 이미지의 작은 영역(지역적 필드)에서 정보를 추출하여 지역적 특징을 학습한다.
- 텍스트에서도 단어별로 정보를 추출하여 지역적 특징을 학습한다.
- MLP와 달리, 이미지의 작은 변화(픽셀 이동)에도 덜 민감하게 반응하여 안정적인 특징을 학습할 수 있다.
- 이러한 장점 때문에 CNN은 이미지 처리에서 뛰어난 성능을 보인다.


2.3. CNN의 컨볼루션 레이어 작동 방식

1. 컨볼루션 레이어의 역할

- 이미지를 그래프로 간주했을 때, 컨볼루션 레이어는 활성화 맵의 값을 업데이트하여 이미지의 상태를 결정한다.
- 입력된 활성화 맵을 받아 처리 후 새로운 활성화 맵을 출력하며, 이 값들이 이미지의 특징을 결정한다.
- 그래프에서는 각 노드의 값이 노드의 특징을 나타내며, 이 정보가 그래프의 상태를 결정한다.

3. 그래프 컨볼루션 네트워크(GCN)의 기본 구조 및 작동 원리

GCN은 CNN의 가중치 공유 및 지역적 특징 추출 원리를 그래프 데이터에 적용하여 노드 정보를 업데이트한다.



3.1. GCN의 핵심 아이디어: 노드 정보 업데이트

1. 그래프 데이터의 특징

- 이미지의 활성화 맵 값이 이미지의 상태를 결정하는 것처럼, 그래프에서는 각 노드에 포함된 값이 노드의 특징을 결정한다.
- 그래프의 형태는 변하지 않지만, 노드 내부의 정보 변화가 그래프의 전체적인 의미를 결정한다.

2. GCN 레이어의 역할

- GCN의 컨볼루션 레이어는 노드를 통과할 때마다 해당 노드의 정보(값)를 업데이트한다.
- 이 업데이트는 주변 노드의 정보를 함께 고려하여 이루어진다.

3.2. GCN의 주요 특징: 가중치 공유와 지역 정보 학습

1. 가중치 공유 (Weight Sharing)

- CNN과 마찬가지로, GCN에서도 동일한 가중치를 여러 노드에 적용하여 파라미터 수를 줄인다.

2. 지역 정보 학습 (Local Information Learning)

- 각 노드는 전체 데이터셋이 아닌, 자신의 주변 노드로부터 정보를 받아 학습한다.
- 이를 '지역 필드(local field)' 또는 '이웃(neighborhood)'이라고 한다.

3.3. GCN의 수학적 표현: 행렬 연산

1. 노드 특징 행렬 업데이트

- 노드 특징 행렬(h)은 각 노드의 정보를 담고 있으며, 레이어를 거치면서 업데이트된다.
- 업데이트는 주변 노드의 정보를 함께 고려하여 이루어진다.

2. GCN 레이어의 수식

- $$h(l+1) = \sigma(D^{-1}A^l D^{-1}h(l)W(l) + b(l))$$
$$h(l+1) = \sigma\left(\frac{1}{2} \hat{A}^l \hat{D}^{-1} h(l) W(l) + b(l)\right)$$
 - $h(l)$: 현재 레이어(l)의 노드 특징 행렬
 - $h(l+1)$: 다음 레이어($l+1$)의 노드 특징 행렬
 - $W(l)$: 현재 레이어(l)의 가중치 행렬
 - $b(l)$: 현재 레이어(l)의 편향(bias)
 - A^l : 정규화된 인접 행렬 (자기 자신을 포함하도록 수정됨)
 - D^l : 정규화된 차수 행렬
 - σ : 활성화 함수 (예: ReLU)
- 이 수식은 각 노드가 자신의 정보와 이웃 노드의 정보를 가중치와 함께 종합하여 다음 레이어의 정보를 업데이트하는 과정을 나타낸다.
- 주변 노드의 정보만 받아들이므로 '지역 정보'를 학습하게 된다.

3. 행렬 연산을 통한 효율성

- 그래프의 연결 정보를 행렬로 표현하면 GPU의 빠른 행렬 연산 능력을 활용하여 병렬 처리가 가능하다.
- 이를 통해 GCN은 효율적으로 그래프 데이터를 처리할 수 있다.

4. 인접 행렬과 노드 특징 행렬의 구체적인 예시

- 그래프 구조를 인접 행렬과 노드 특징 행렬로 표현하는 과정을 시각적으로 설명한다.
- 인접 행렬은 노드 간의 연결 여부를 0과 1로 나타낸다.
- 노드 특징 행렬은 각 노드의 정보를 담고 있으며, 설정된 특징 수에 따라 크기가 결정된다.
- 행렬 곱셈을 통해 노드 특징이 업데이트되는 과정을 설명한다.
- 각 열은 특정 필터(특징)에 해당하며, 노드 특징 행렬에 곱해져 새로운 노드 특징을 생성한다.
- 컨볼루션 레이어는 필터 연산을 통해 더 높은 차원의 정보를 추출한다.
- 인접 행렬과 노드 특징 행렬을 곱하는 연산은 CNN의 컨볼루션 연산과 유사하게 작동한다.

3.4. GCN의 구현 및 확장 기법

1. GCN 레이어의 구현 상세

- GCN 레이어는 노드 특징 행렬과 인접 행렬을 사용하여 노드 정보를 업데이트한다.
- GPU를 활용한 행렬 연산으로 효율성을 높인다.

2. 그래프 컨볼루션 레이어의 작동 방식

- 그래프 컨볼루션 레이어는 노드 정보를 업데이트하며, 주변 노드의 정보를 활용한다.
- 자기 자신의 정보도 유지하며 업데이트에 반영한다.
- 인접 행렬에서 자기 자신과의 연결(대각선 요소)을 1로 설정하는 이유를 설명한다.

3. 차원 결정 및 필터의 역할

- 이전 레이어의 노드 수와 현재 레이어의 필터 수가 다음 레이어의 차원을 결정한다.
- 각 열은 특정 필터에 해당하며, 여러 필터를 사용하여 다양한 특징을 추출한다.

4. 분자 그래프 예시 및 특징 추출

- 분자 그래프를 예시로 들어, 원자 정보를 노드 특징으로 사용하고 그래프 컨볼루션 연산을 통해 분자의 특성을 예측하는 과정을 설명한다.
- 최종적으로 완전 연결 레이어를 통해 그래프 전체의 정보를 종합하여 예측을 수행한다.

5. GCN의 구조 및 활용

- GCN은 그래프 구조 데이터를 처리하기 위한 효과적인 모델이다.
- CNN처럼 마지막에 완전 연결 레이어를 사용하여 예측을 수행한다.
- 그래프의 각 노드별 예측 또는 그래프 전체의 예측이 가능하다.

6. 노드 순서 불변성 (Permutation Invariance)

- 그래프의 노드 순서가 바뀌어도 동일한 그래프로 인식되어야 한다.
- 이를 위해 '풀링(pooling)' 또는 '정렬(sorting)'과 같은 과정을 거치는 '다운 레이어(down layer)'를 사용한다.
- '퍼뮤테이션(permutation)'은 노드 순서 변경을 의미하며, '다운 레이어'는 이러한 순서 변경에 영향을 받지 않도록 한다.

7. GCN의 기본 구조 및 확장 기법

- **그래프 컨볼루션 레이어**: 노드 정보를 업데이트하고 주변 정보를 활용한다.
- **활성화 함수**: 비선형성을 추가한다.
- **다운 레이어**: 노드 정보를 종합하여 벡터 형태로 만든다.
- **최종 예측 레이어**: CNN의 완전 연결 레이어와 유사하게 사용된다.
- **인셉션 모듈 (Inception Module)의 적용**: 다양한 크기의 필터를 사용하여 더 넓은 범위의 정보를 포착한다.
 - 그래프 컨볼루션 레이어를 여러 번 적용하여 멀리 떨어진 노드의 정보까지 포함시킨다.
- **잔차 연결 (Residual Connection)**: 깊은 네트워크에서 발생하는 기울기 소실 문제를 완화한다.

- 이전 레이어의 정보를 직접 다음 레이어로 전달하여 학습을 돕는다.
- **KT-DS 연결 (KT-DS Connection):** 원본 정보와 업데이트된 정보를 적절한 비율로 조합한다.
 - '게이트(gate)' 메커니즘을 사용하여 정보를 혼합한다.
- **어텐션 (Attention):** 노드 업데이트 시 연결된 노드들의 중요도를 학습하여 가중치를 부여한다.
 - 노드 간의 상관관계 중요도를 나타내는 '알파(alpha)' 값을 학습한다.
 - 이를 통해 각 노드에 대한 적절한 비율로 정보를 받아들인다.

4. GCN의 실제 적용 및 요약

GCN은 그래프 데이터를 효과적으로 처리하여 다양한 예측 및 분석 작업에 활용될 수 있다.



4.1. GCN의 학습 과정 및 목표

1. 파라미터 업데이트

- 손실 함수(loss)를 기반으로 가중치(W)와 편향(b) 등의 파라미터가 업데이트된다.
- 이 과정에서 GCN 레이어의 가중치와 알파 값 등이 최적화된다.

2. 학습 목표

- 그래프에서 적절한 특징을 추출하여 원하는 예측을 수행하는 것이다.

4.2. GCN의 활용 예시: 분자 특성 예측

1. 분자 그래프 데이터

- 분자를 그래프로 표현하고, 각 원자를 노드로, 결합을 간선으로 나타낸다.

- 원자의 종류(탄소, 수소 등)는 노드 특징으로 사용된다.

2. 그래프 컨볼루션 연산

- GCN을 통해 분자 그래프의 정보를 업데이트하고 압축하여 벡터 형태로 만든다.
- 이 과정에서 분자 전체의 정보와 고차원적인 특징을 학습한다.

3. 예측 및 학습

- 최종적으로 완전 연결 레이어를 통해 분자의 특정 속성(예: 용해도, 독성)을 예측한다.
- 실제 값과의 차이를 손실 함수로 사용하여 모델을 학습시킨다.
- GCN은 이미지의 특징 추출과 유사하게, 분자 데이터에서 의미 있는 특징을 학습한다.

4.3. 오늘 학습 내용 요약

1. 그래프의 정의 및 표현

- 그래프는 정점(노드)과 간선으로 구성되며, 인접 행렬과 노드 특징 행렬로 표현된다.

2. GCN의 기본 원리

- 가중치 공유와 지역적 특징 추출을 통해 그래프 데이터를 처리한다.
- 행렬 연산을 활용하여 효율적으로 노드 정보를 업데이트한다.

3. GCN의 확장 기법

- 다양한 크기의 필터(인셉션), 잔차 연결, KT-DS 연결, 어텐션 등을 활용하여 성능을 향상시킨다.
- 각 기법은 노드 정보 업데이트 및 특징 추출 방식을 개선한다.

4. 향후 학습 내용

- 이론 학습 후 실제 코드를 구현하는 실습 시간을 갖는다.