


STEP 7. 신뢰도(Confidence) 산출 방법론 (2~3주)

딥러닝 모델의 불확실성을 정량화하는 방법은 무엇인가? 딥 앙상블은 여러 독립적인 신경망을 학습시켜 예측의 분산을 활용하고, MC 드롭아웃은 단일 신경망에서 드롭아웃을 적용하여 테스트 시 여러 번의 순방향 전달을 통해 불확실성을 추정합니다.

1. 딥러닝 모델의 불확실성 정량화 방법

딥러닝 모델의 예측 불확실성을 정량화하는 것은 모델의 신뢰도를 파악하는 데 중요하다.



1.1. 불확실성 정량화의 필요성

1. **이전 강의 내용 복습:** 이전 강의에서는 모델의 '보정(calibration)'에 대해 논의했다.
2. **보정 학습의 중요성:** 확률적 머신러닝 과정에서 보정이라는 주제를 배우는 이유는 모델의 예측이 얼마나 신뢰할 수 있는지 이해하기 위함이다.
 - 모델은 물리적 계측기와 달리 관측이 아닌 예측을 위해 사용된다.
3. **핵심 질문:** 신경망에서 불확실성을 어떻게 추출할 수 있는가?

1.2. 불확실성 추출을 위한 기존 방법론

1. 베이즈적 접근:

- 가중치(weights)에 대한 확률 분포를 가정하고, 이를 통해 예측의 불확실성을 추정한다.
- 가우시안 분포를 가중치에 대한 사전 분포(prior)로 설정할 수 있다.
- 사후 분포(posterior)를 얻는 것이 중요하며, 이는 베이즈 선형 회귀에서는 적분으로 해결 가능하지만 신경망에서는 복잡하다.

2. 근사적 방법론:

- **라플라스 근사(Laplace approximation):** 헤세 행렬(Hessian matrix)을 다루는 것이 복잡할 수 있다.
- **샘플링 기법 (MCMC, rejection sampling, importance sampling 등):** 많은 샘플을 추출해야 하므로 절차가 느릴 수 있다.

3. 결과 해석:

- 이러한 방법들을 통해 얻은 사후 예측 분포(posterior predictive)는 몬테카를로 추정(Monte Carlo estimation)을 통해 얻을 수 있다.
- 하지만 이러한 방법들은 구현이 어렵고 시간이 오래 걸리는 단점이 있다.

1.3. 새로운 불확실성 정량화 방법론 소개

1. 오늘 다룰 두 가지 방법:

- 딥 앙상블 (Deep Ensemble)
- 몬테카를로 드롭아웃 (Monte Carlo Dropout)

2. 방법론의 단순성: 이 방법들은 매우 간단하며, 기존의 복잡한 방법론에 비해 쉽게 적용 가능하다.

3. 랜덤 포레스트와 불확실성: 랜덤 포레스트와 같은 통계적 빈도주의 방법론에서도 불확실성을 얻을 수 있으며, 이는 베이즈적 방법론과 반드시 동일하지 않음을 시사한다.

- 랜덤 포레스트는 일반적으로 이산적인 최적화 문제를 해결하므로 직접적인 불확실성 측정이 어렵다.

4. 신경망에서의 불확실성:

- **알레아토릭 불확실성(Aleatoric uncertainty):** 분산(variance)을 손실 함수(loss term)에 포함시켜 모델링할 수 있다.

- **에피스테믹 불확실성(Epistemic uncertainty):** 가중치에 대한 사전 분포를 설정하고 사후 분포를 추정해야 한다.

5. 앙상블의 이점:

- 여러 개의 독립적인 모델을 학습시켜 예측의 편차를 통해 불확실성을 파악한다.
- 결정 트리와 같이 단순한 모델 여러 개를 결합하면 더 복잡한 경계(예: 원형 경계)를 학습할 수 있다.

6. 딥 앙상블 (Deep Ensemble):

- 동일한 데이터셋으로 여러 개의 독립적인 신경망을 학습시킨다.
- 각 신경망은 독립적으로 학습되며, 이를 통해 여러 예측값을 얻고 분산을 계산한다.
- 데이터셋의 다른 부분집합을 사용하거나 다른 초기화 값을 사용하여 다양한 모델을 생성할 수 있다.
- 단점: 학습 시간이 오래 걸리고 메모리 사용량이 많다.

7. 몬테카를로 드롭아웃 (Monte Carlo Dropout):

- 단일 신경망을 학습시키고, 테스트 시 여러 번의 순방향 전달(forward pass) 동안 드롭아웃을 적용하여 불확실성을 추정한다.
- 장점: 학습 시간이 효율적이다.

8. 기타 방법론:

- 헤테로세다스틱 가능도(Heteroscedastic likelihood): 입력에 따라 분산이 달라지는 가우시안 분포를 가정한다.
- 이 방법들은 알레아토릭 및 에피스테믹 불확실성을 모두 포착한다.


9. 참고 자료:

- University of Amsterdam의 관련 강의 노트 및 코드를 참고할 수 있다.

2. 딥 앙상블 (Deep Ensemble)

딥 앙상블은 동일한 데이터셋으로 여러 개의 독립적인 신경망을 학습시키고, 이들의 예측 편차를 통해 불확실성을 추정하는 방법이다.

딥 앙상블 (Deep Ensemble)



2.1. 딥 앙상블의 원리

1. **기본 개념:** 여러 개의 독립적인 신경망을 학습시켜 예측의 분산을 활용한다.
2. **학습 방식:**
 - 동일한 데이터셋을 사용하여 여러 개의 독립적인 신경망을 학습시킨다.
 - 다양한 모델을 생성하기 위해 다른 초기화 값을 사용하거나, 데이터셋의 다른 부분 집합을 사용할 수 있다.
3. **예측 및 불확실성 추정:**
 - 각 신경망 멤버로부터 예측값을 얻는다.
 - 이 예측값들의 분산을 계산하여 불확실성을 추정한다.
4. **장단점:**
 - 장점: 예측의 편차를 통해 불확실성을 파악할 수 있다.
 - 단점: 여러 모델을 독립적으로 학습시키므로 학습 시간이 오래 걸리고 메모리 사용량이 많다.

2.2. 딥 앙상블 구현 예시

1. **데이터셋:**
 - 데이터 밀도가 다른 인공적으로 생성된 데이터셋을 사용한다.

- 데이터가 희소한 영역에서는 불확실성이 높아야 한다.

2. MLP 모델 구현:

- `nn.linear` 를 사용하지 않고 직접 가중치(W)와 편향(B)을 사용하여 MLP를 구현한다.
- 이는 드롭아웃 구현을 보여주기 위함이며, 실제로는 `nn.linear` 와 `nn.dropout` 사용을 권장한다.
- PyTorch에서 "non-leaf nodes cannot be optimized"와 같은 오류를 피하기 위해 계산 그래프에 주의해야 한다.

3. 학습 과정:

- 학습 전 모델의 예측을 확인하여 정상 작동 여부를 검증한다.
- Tanh 활성화 함수가 ReLU보다 더 나은 성능을 보였다.
- 학습 중 손실(loss)이 빠르게 감소하지 않거나 멈추는 현상이 발생할 수 있으며, 이는 출력 차원 불일치 등의 버그로 인한 것일 수 있다.
- `torch.no_grad()` 를 사용하여 테스트 데이터에 대한 계산 그래프 생성을 방지하고 메모리를 절약한다.

4. 딥 앙상블 적용:

- 5개의 멤버로 구성된 앙상블을 학습시킨다.
- 각 멤버의 손실이 빠르게 감소하는 것을 확인한다.
- 결과 플롯에서 각 신경망의 예측이 다르게 나타나는 것을 볼 수 있다.


5. 결과 해석:

- 데이터가 없는 영역(test X)에서 예측 분포의 변동성이 더 크게 나타난다.
- 데이터가 희소한 영역에서 불확실성이 높게 나타나는 것을 확인할 수 있다.
- 불확실성 플롯을 별도로 그려 불확실성 정도를 명확히 파악한다.

3. 몬테카를로 드롭아웃 (Monte Carlo Dropout)

몬테카를로 드롭아웃은 단일 신경망에서 드롭아웃을 적용하여 테스트 시 여러 번의 순방향 전달을 통해 불확실성을 추정하는 방법이다.

몬테카를로 드롭아웃 (MC Dropout)



3.1. 드롭아웃 (Dropout)의 기본 원리

1. **드롭아웃의 목적:** 신경망의 과적합(overfitting)을 방지하기 위해 도입되었다.
2. **핵심 아이디어:** 신경망의 특정 노드(뉴런)를 미리 정의된 확률로 제거한다.
3. **작동 방식:**
 - 각 반복마다 신경망의 구조가 변경되는 것은 아니다.
 - 대신, 활성화 값(activation) 이후에 특정 노드를 0으로 만든다.
4. **구현 시 고려사항:**
 - 드롭아웃 확률(P)을 설정하고, 이를 기반으로 마스크(mask)를 생성하여 활성화 값에 곱한다.
 - $H1 = H1 / (1 - P)$ 와 같이 스케일링을 통해 활성화 값의 기댓값을 보정하여 편향을 줄인다.

3.2. 몬테카를로 드롭아웃 구현 및 실험

1. **드롭아웃 적용:**
 - MLP 모델에 드롭아웃을 적용하여 학습시킨다.
 - 드롭아웃 적용 시 손실(loss)이 이전보다 느리게 감소하며, 더 노이즈가 많아질 수 있다.
2. **테스트 시 드롭아웃:**

- 테스트 시에도 드롭아웃을 활성화하면(training=False), 각 순방향 전달마다 다른 예측값을 얻게 된다.
- 이 경우 모델이 과소적합(underfitting)될 수 있으며, 예측 성능이 저하될 수 있다.

3. 해결 방안:

- 드롭아웃 확률(P)을 낮추거나, 모델을 더 복잡하게 만들거나, 잔차 연결(residual connection)을 추가하는 방법을 고려할 수 있다.

4. 잔차 연결 (Residual Connection) 도입:

- H1과 H2 레이어 사이에 잔차 연결을 추가하여 모델의 복잡성을 높인다.
- 잔차 연결을 사용하면 모델 성능이 향상되고, 딥 앙상블과 함께 사용 시에도 좋은 결과를 얻는다.

5. MC 드롭아웃과 잔차 연결의 결합:

- 잔차 연결을 사용하면서 드롭아웃을 적용하고, 스케일링을 통해 성능을 개선한다.
- 드롭아웃을 첫 번째 레이어가 아닌 이후 레이어에 적용하고, 스케일링을 올바르게 적용하는 것이 중요하다.
- 스케일링을 적용하지 않으면 편향이 발생할 수 있다.

6. 테스트 시 드롭아웃 활용:

- 테스트 시에도 드롭아웃을 활성화하고 여러 번의 순방향 전달을 수행한다.
- 이전보다 개선된 예측 성능과 불확실성 추정을 얻을 수 있다.
- 잔차 연결과 올바른 스케일링, 드롭아웃 적용 위치 등을 통해 불확실성이 데이터가 없는 영역에 집중되도록 개선한다.

3.3. MC 드롭아웃의 이론적 배경

1. 명칭의 유래: "몬테카를로"라는 이름은 몬테카를로 방법론의 특성에서 비롯된다.

2. 베이즈적 근사:

- "Dropout as Bayesian Approximation" 논문에서 드롭아웃을 딥 신경망에서의 근사적 베이즈 추론으로 해석한다.
- 드롭아웃은 딥 가우시안 프로세스에서의 근사적 베이즈 추론으로 간주될 수 있다.

3. 수학적 설명:

- 가중치에 대한 사후 분포 $P(W|X, Y)$ 를 직접 얻을 수 없기 때문에, 이를 근사하는 방법을 사용한다.

- 드롭아웃을 통해 얻은 가중치는 특정 속성을 가진 근사 사후 분포에서 샘플링된 것으로 볼 수 있다.
 - 이론적으로는 가우시안 프로세스 및 변분 추론(variational approximation)에 대한 이해가 필요하다.
4. **실제 적용:** 복잡한 수학적 이해 없이도 드롭아웃을 적용하여 불확실성을 추정할 수 있다.