

3. 분산시스템 신뢰성 (SLO)

1. 서비스 신뢰성 확보를 위한 핵심 원칙: SLO와 SLI

서비스의 신뢰성은 사용자의 만족도와 직결되며, 이를 체계적으로 관리하기 위해 서비스 수준 목표(SLO)와 서비스 수준 지표(SLI)를 활용해야 한다.

1.1. 서비스 신뢰성의 중요성과 측정 방법

- 시스템의 가장 중요한 특징은 신뢰성이다.
- 신뢰성은 사용자의 신뢰와 존경을 얻는 데 필수적이며, 서비스가 불안정하면 사용자 경험 설계 노력이 헛수고가 될 수 있다.
- 신뢰성은 조직 내 여러 부서가 공유해야 할 목표이며, 계획, 설계, 건축, 측정이 필요하다.
- 서비스의 신뢰성을 측정하는 한 가지 방법은 가동 시간 비율을 사용하는 것이지만, 복잡한 시스템에서는 정의하고 측정하기 어렵다.
- 대신 이벤트 기반 또는 상호작용 기반 모델을 사용하여 성공률을 구할 수 있다.
 - 특정 기간 동안 사용자가 서비스와 상호 작용을 시도한 횟수를 세고, 성공적인 시도 횟수를 전체 시도 횟수로 나누어 성공률을 계산한다.
- 무엇을 상호작용으로 정의하고 무엇이 성공적인 상호작용을 만드는지는 서비스 종류에 따라 달라진다.
 - 웹사이트나 모바일 앱의 경우 HTTP 요청을 상호 작용 수단으로 사용할 수 있다.
- 실제로 측정하고 집계하는 것은 서비스 수준 지표(SLI)라고 한다.
- "좋은" 또는 "성공적인"에 대한 정의는 서비스를 이용하는 사용자의 기대에 달려 있다.
 - 예를 들어, 프로필 페이지의 성공 여부를 HTTP 200 응답 코드를 수신하는 것으로 정의할 수 있다.
- 안정성 측정값 저하를 막기 위해 클라이언트 구성 오류로 인한 400 오류 코드는 집계에서 제외할 수 있다.

1.2. 서비스 수준 목표(SLO) 설정

- 서비스의 안정성 목표를 설정하는 것을 서비스 수준 목표(SLO)라고 한다.
- SLO는 SLI, 임계값, 평가 기간의 조합이다.

- 핵심은 사용자가 만족하는 기준점 또는 임계값을 설정하는 것이다.
- 목표를 100%로 설정하는 것은 달성 불가능하며, 서비스 및 생산에 아무런 변화를 주지 못할 수 있다.
- SLO 목표 설정의 경험 법칙은 해당 서비스가 목표치에 맞춰 작동할 때 일반적인 서비스 사용자가 대체로 만족할 것이라는 점이다.
 - 신뢰도가 조금이라도 떨어지면 고객 기대 충족에 실패하고 불만을 갖기 시작한다.
- 이를 "행복 테스트"라고 부른다.
- 신뢰도 목표를 초과 달성하는 것에도 단점이 있다.
 - 사용자가 서비스 안정성에 만족한다면, 추가적인 안정성 확보는 큰 의미가 없다.
 - 오히려 추가 자원을 새로운 기능 개발이나 서비스 개선에 사용하면 사용자가 더 만족할 수 있다.
- 서비스의 핵심 특징으로 신뢰성을 정의하고, 신뢰성 측정에는 SLI를, 신뢰성 목표 설정에는 SLO를 사용한다.

1.3. SLO 모니터링 및 클라우드 운영 활용

- SLO 모니터링과 클라우드 운영을 활용하여 SLO를 달성할 수 있다.
- 클라우드 콘솔의 프로젝트 대시보드에서 모니터링 메뉴로 이동하여 서비스를 선택하면 서비스 목록을 확인할 수 있다.
 - 서비스는 App Engine, GA 엔티티, Istio 서비스 메시, Anthos 서비스에서 자동으로 생성되거나 사용자 지정으로 정의할 수 있다.
- SLO에서 경고가 발생하는 열을 기준으로 목록을 정렬하면 현재 문제가 있는 서비스를 파악할 수 있다.
- 특정 서비스의 SLO 현황을 자세히 살펴보면 다음과 같다.
 - 월별 응답 지연 시간 SLO는 양호한 수준이며 오류 허용량도 충분하다.
 - 롤링 윈도우 가용성 SLO도 양호한 수준이다.
 - 1주일 단위의 지연 시간 SLO는 오류 허용 범위는 충분하지만 현재 양호한 상태가 아니다.
- SLI가 목표에 대해 어떻게 작동하는지 확인하면 목표 달성에 어려움을 겪는 기간을 파악할 수 있다.
- 오차 예산 탭에서는 선택한 기간 동안의 오차 예산 소모량을 보여준다.

- 급격한 증가는 달력 기반 SLO 대신 롤링 SLO를 사용하는 것이 위험할 수 있음을 보여준다.
- 서비스의 다양한 성능 및 상태 지표를 자동으로 수집하여 제공한다.
 - GKE 네임스페이스 기반 서비스의 경우 해당 네임스페이스의 컨테이너, 파드, 노드 메트릭에 접근할 수 있다.
 - 컨테이너 재시작 및 가동 시간 보기를 통해 서비스 안정성을 확인할 수 있다.
 - 여러 컨테이너가 거의 동시에 재시작된 것을 확인할 수 있다.
- 서비스에서 출력되는 로그와 Kubernetes 엔티티 세부 정보도 확인할 수 있다.
- 클라우드 운영에서 SLO 모니터링은 SLO를 사용하여 서비스 안정성을 측정하고 문제를 식별, 분류, 완화하는 데 필요한 정보를 통합 제공한다.
- 이 에피소드에서는 서비스 유형, 신뢰성의 중요성, SLI를 사용한 신뢰성 측정 방법, SLO를 사용한 신뢰성 목표 설정 방법, 그리고 클라우드 운영에서의 SLO 모니터링 활용 방법을 다루었다.

2. 지연 시간 측정의 함정과 올바른 접근법

지연 시간 측정은 단순해 보이지만, 잘못된 측정 방식은 시스템의 실제 상태를 왜곡하고 잘못된 의사결정을 유발할 수 있다.

2.1. 지연 시간 측정의 흔한 오류

- 지연 시간은 특정 작업이 완료되는 데 걸리는 시간이며, 수백만 건의 작업이 있다면 백만 개의 지연 시간이 존재한다.
- 중요한 것은 개별 지연 시간이 아니라, 이 백만 개의 지연 시간이 어떻게 행동하는지, 즉 분포를 이해하는 것이다.
- 모니터링 시스템에서 흔히 보이는 백분위수(percentile) 차트는 종종 진실을 숨긴다.
 - 95번째 백분위수만 보여주는 차트는 5%의 최악의 상황을 보여주지 않으며, 이는 마케팅에는 유용할 수 있으나 실제 문제 파악에는 부적합하다.
 - 이러한 차트는 "좋은 것들만 보여주는 차트"이며, 실제로는 숨겨진 나쁜 데이터를 보여주지 않는다.
- 최대값(maximum value)은 숨겨진 진실을 드러내는 중요한 신호이며, 노이즈가 아니라 신호이다.
- 백분위수를 평균내는 것은 의미 없는 행위이며, 이는 사람들을 오도하는 방법이다.

- 예를 들어, 95번째 백분위수의 평균은 실제 95번째 백분위수가 아님을 생각하게 만든다.
- 99번째 백분위수조차도 웹 페이지 로딩 시 여러 요청이 발생하면 사용자가 경험할 확률이 높아진다.
 - 99번째 백분위수가 1%의 사용자에게만 해당된다고 생각하기 쉽지만, 실제로는 더 많은 사용자가 경험할 수 있다.
- 99.997%의 사용자가 95번째 백분위수보다 나쁜 경험을 볼 수 있으며, 이는 95번째 백분위수가 왜 중요한지 의문을 갖게 한다.
- 중앙값(median)은 가장 흔하게 사용되지만, 실제 경험하는 지연 시간과는 거리가 멀 수 있다.
- 높은 백분위수(예: 다섯 개의 9, 즉 99.999%)를 측정하기 어려운 이유는 다음과 같다.
 - 백분위수를 평균낼 수 없고, 짧은 시간 샘플로는 긴 시간의 높은 백분위수를 추정하기 어렵다.
- HDR 히스토그램(hdr histogram)은 전체 백분위수 스펙트럼을 얻을 수 있게 해주는 도구이다.

2.2. 좌표 누락 문제(Coordinate Omission)

- 좌표 누락 문제는 측정 시점과 다음 측정 시점 사이에 시스템이 느려지거나 멈추는 경우, 해당 구간의 데이터를 누락시키는 현상이다.
 - 로드 제너레이터는 다음 요청을 보내야 하는 시간까지 측정이 완료되지 않으면 해당 측정을 건너뛴다.
 - 코드 내에서 측정할 때도 시스템이 멈추면 해당 구간의 데이터가 누락될 수 있다.
- 이로 인해 실제로는 시스템이 느려졌음에도 불구하고 측정 결과는 좋게 나올 수 있다.
- 예를 들어, 100초 동안 1밀리초씩 작동하다가 100초 동안 멈추는 시스템을 측정하면,
 - 실제로는 25초의 평균 지연 시간을 갖지만, 일반적인 측정 도구는 10.9밀리초라는 왜곡된 결과를 보여줄 수 있다.
 - 이러한 측정 결과는 시스템이 완벽하다고 착각하게 만들며, 이는 심각한 문제를 야기한다.
- 좌표 누락 문제는 측정 데이터가 매우 선택적으로 수집되어 발생하는 것으로, 무작위 샘플링이 아니다.
- "제어 Z(Control Z) 테스트"를 통해 좌표 누락 문제를 확인할 수 있다.

- 응답 시간(Response Time)과 서비스 시간(Service Time)을 구분해야 한다.
 - 서비스 시간은 실제 작업에 걸리는 시간이고, 응답 시간은 대기 시간을 포함한 총 시간이다.
 - 좌표 누락 문제는 응답 시간이 아닌 서비스 시간만 측정하게 만들어, 대기 시간을 숨긴다.
- 부하가 증가하면 서비스 시간은 일정하지만 응답 시간은 급격히 증가한다.
- 시스템의 처리량 한계를 넘어서면 응답 시간이 선형적으로 증가하는 것을 볼 수 있으며, 이를 보여주지 못하는 로드 제너레이터는 신뢰할 수 없다.

2.3. 올바른 지연 시간 측정 및 분석

- 지연 시간은 반드시 부하(load)의 맥락에서 봐야 한다.
- 시스템의 지속 가능한 속도(sustainable speed)는 시스템이 멈추지 않고 처리할 수 있는 최대 부하를 의미한다.
- 시스템이 한계에 도달했을 때의 행동을 측정하는 것은 유용하지만, 그 이후의 행동을 연구하는 것은 무의미하다.
- 중요한 것은 시스템이 언제 한계에 도달하는지(hitting the pole)를 파악하는 것이다.
- 요구사항(requirements)을 설정하고, 시스템이 해당 요구사항을 충족하는지 확인해야 한다.
- 시스템의 성능을 비교할 때는 한계점 근처가 아닌, 충분히 여유 있는 부하에서 비교해야 한다.
 - 시스템이 한계에 도달했을 때 어느 시스템이 더 낮다고 판단하는 것은 잘못된 접근이다.
 - 시스템의 "무릎(knee)" 지점, 즉 한계점에 가까운 지점은 피해야 한다.
- 처리량의 절반 정도에서 시스템을 비교하면 더 의미 있는 결과를 얻을 수 있다.
- 시스템이 얼마나 많은 부하를 처리할 수 있는지, 그리고 그 과정에서 응답 시간이 어떻게 변하는지를 이해하는 것이 중요하다.
- HDR 히스토그램과 같은 도구를 사용하여 전체 백분위수 스펙트럼을 분석해야 한다.
- 최대값을 포함한 모든 데이터를 측정하고 분석하는 것이 중요하다.
- 올바른 측정을 위해서는 좌표 누락 문제를 해결해야 하며, 이를 위해 Gatling, GitHub 버전의 YCSB, wrk2와 같은 도구를 활용할 수 있다.

- Cassandra Stress 2와 같이 응답 시간과 서비스 시간을 모두 보고하는 도구도 유용하다.
- 측정 도구 자체의 신뢰성이 중요하며, 잘못 측정하는 도구를 사용하면 데이터 자체가 잘못된다.
- 수직 상승하는 그래프는 좌표 누락의 강력한 징후일 수 있다.
- 제어 Z 테스트는 좌표 누락 문제를 진단하는 간단한 방법이다.
- 올바르게 측정된 지연 시간 데이터는 부드러운 곡선 형태를 보이며, 수직 상승은 누락을 의미한다.
- 결국, 지연 시간 측정의 핵심은 시스템의 한계를 이해하고, 사용자가 실제로 경험하는 성능을 정확하게 파악하는 것이다.